

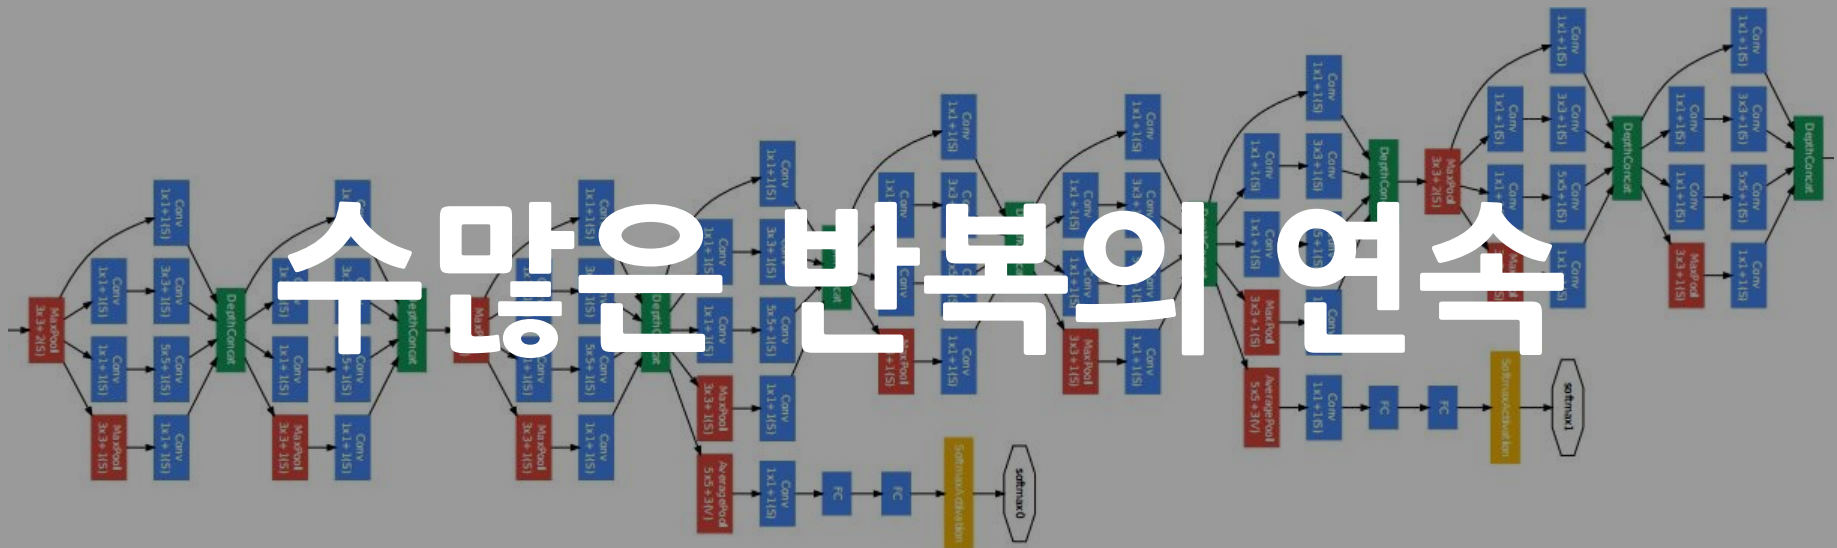
AutoGrad & Optimizer

TEAMLAB director

최성철


WARNING: 본 교육 콘텐츠의 지식재산권은 재단법인 네이버커넥트에 귀속됩니다. 본 콘텐츠를 어떠한 경로로도 외부로 유출 및 수정하는 행위를 엄격히 금합니다. 다만, 비영리적 교육 및 연구활동에 한정되어 사용할 수 있으나 재단의 허락을 받아야 합니다. 이를 위반하는 경우, 관련 법률에 따라 책임을 질 수 있습니다.

논문을 구현해 보자!




Layer = Block

Modularity (¼)



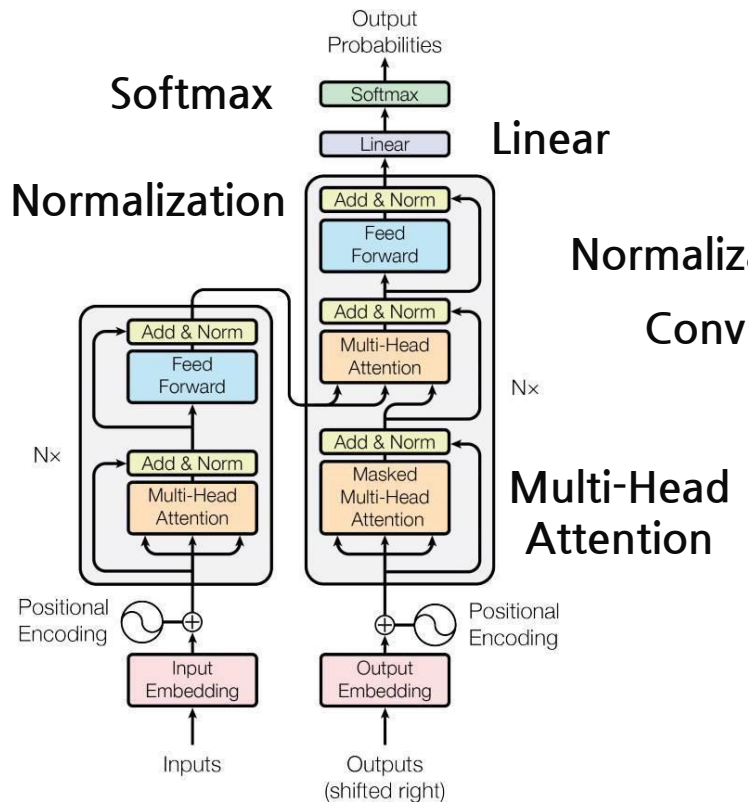
DNN models can be composed just like building LEGO buildings

<https://bit.ly/3lv0eAJ>

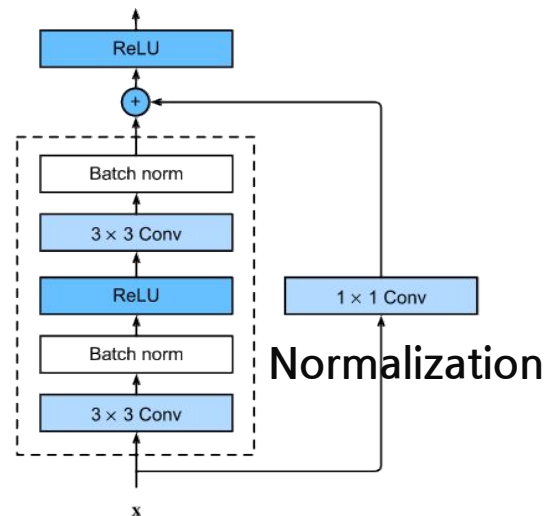



<https://bit.ly/3lxGTPe>



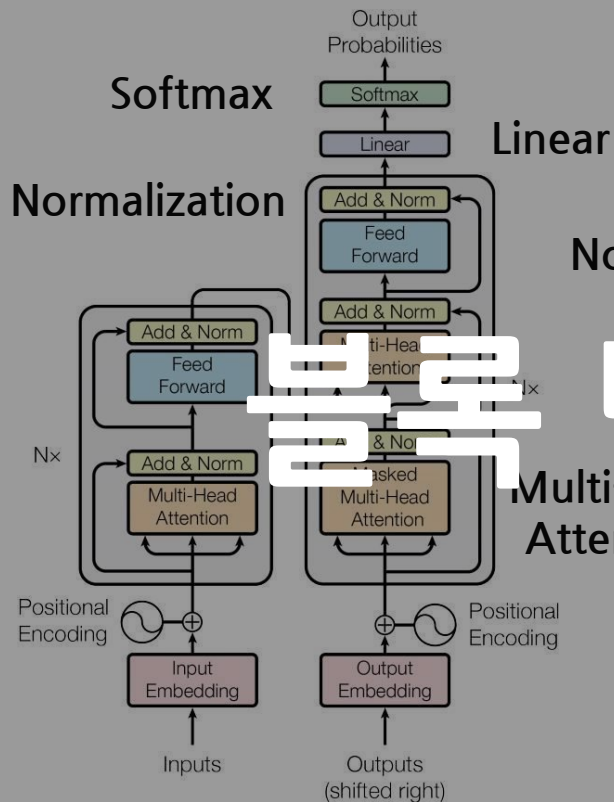
http://cs231n.stanford.edu/slides/winter1516_lecture5.pdf



<https://machinelearningmastery.com/the-transformer-model/>



https://d2l.djl.ai/chapter_convolutional-modern/resnet.html




블록 반복의 연속


torch.nn.Module

- 딥러닝을 구성하는 Layer의 base class
- Input, Output, Forward, Backward 정의
- 학습의 대상이 되는 parameter(tensor) 정의

Forwardpass



Backwardpass



<https://github.com/Vercaca/NN-Backpropagation>

- Tensor 객체의 상속 객체
 - nn.Module 내에 attribute가 될 때는 required_grad=True로 지정되어 학습 대상이 되는 Tensor
 - 우리가 직접 지정할 일은 잘 없음
- : 대부분의 layer에는 weights 값들이 지정되어 있음

```
class MyLinear(nn.Module):
    def __init__(self, in_features, out_features, bias = True):
        super().__init__()
        self.in_features = in_features
        self.out_features = out_features
        self.weights = nn.Parameter(
            torch.randn(in_features, out_features))
        self.bias = nn.Parameter(torch.randn(out_features))

    def forward(self, x: Tensor):
        return x @ self.weights + self.bias
```

- Layer에 있는 Parameter들의 미분을 수행
- Forward의 결과값 (model의 output=예측치)과 실제값간의 차이(loss)에 대해 미분을 수행
- 해당 값으로 Parameter 업데이트

```
for epoch in range(epochs):  
    ... ..  
    # Clear gradient buffers because we don't want any gradient from previous epoch to carry forward  
    optimizer.zero_grad()  
  
    # get output from the model, given the inputs  
    outputs = model(inputs)  
  
    # get loss for the predicted output  
    loss = criterion(outputs, labels)  
    print(loss)  
    # get gradients w.r.t to parameters  
    loss.backward()  
  
    # update parameters optimize  
    optimizer.step()  
    ... ..
```

- 실제 **backward**는 **Module** 단계에서 직접 지정가능
- **Module**에서 **backward** 와 **optimizer** 오버라이딩
- 사용자가 직접 미분 수식을 써야하는 부담
→ 쓸 일은 없으나 순서를 이해할 필요는 있음

```
class LR(nn.Module):
    def __init__(self, dim, lr = torch.scalar_tensor(0.01)):
        super(LR, self).__init__()
        # initialize parameters
        self.w = torch.zeros(dim, 1, dtype = torch.float).to(device)
        self.b = torch.scalar_tensor(0).to(device)
        self.grads = {'dw': torch.zeros(dim, 1, dtype = torch.float).to(device),
                      'db': torch.scalar_tensor(0).to(device)}

        self.lr = lr.to(device)
```

```
def forward(self, x):
    # compute forward
    z = torch.mm(self.w.T, x)
    a = self.sigmoid(z)
    return a
```

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

```
def sigmoid(self, z):
    return 1 / (1 + torch.exp(-z))
```

```
def backward(self, x, yhat, y):
    ## compute backward
    self.grads['dw'] = (1 / x.shape[1]) * torch.mm(x, (yhat - y).T)
    self.grads['db'] = (1 / x.shape[1]) * torch.sum(yhat - y)
```

```
def optimize(self):
    ## optimization step
    self.w = self.w - self.lr * self.grads['dw']
    self.b = self.b - self.lr * self.grads['db']
```

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_j^i$$

$$\begin{aligned} \theta_j &:= \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta) \\ &:= \theta_j - \alpha \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_j^i \end{aligned}$$

End of Document
Thank You.