PyTorch Troubleshooting

TEAMLAB director

최성철

공포의 단어
OOM

OOM이 해결하기 어려운 이유들…

- 왜 발생했는지 알기 어려움
- 어디서 발생했는지 알기 어려움
- Error backtracking 이 이상한데로 감
- 메모리의 이전상황의 파악이 어려움

Batch Size ↓

→ GPU clean → Run

그 외에 발생할 수 있는 문제들...

GPUUtil 사용하기

- nvidia-smi 처럼 GPU의 상태를 보여주는 모듈
- Colab은 환경에서 GPU 상태 보여주기 편함
- iter마다 메모리가 늘어나는지 확인!!

```
!pip install GPUtil
```

```
import GPUtil
```

```
GPUtil.showUtilization()
```

```
-----------------
|  0 |  2% |  6% |
|  1 |  0% | 90% |
| ID | GPU | MEM |
-----------------
```

torch.cuda.empty_cache() 써보기

- 사용되지 않은 GPU상 cache를 정리
- 가용 메모리를 확보
- del 과는 구분이 필요
- reset 대신 쓰기 좋은 함수

torch.cuda.empty_cache() 써보기


```
import torch
from GPUtil import showUtilization as gpu_usage

print("Initial GPU Usage")
gpu_usage()

tensorList = []
for x in range(10):
    tensorList.append(torch.randn(10000000,10).cuda())

print("GPU Usage after allcoating a bunch of Tensors")
gpu_usage()

del tensorList

print("GPU Usage after deleting the Tensors")
gpu_usage()

print("GPU Usage after emptying the cache")
torch.cuda.empty_cache()
gpu_usage()
```

Initial GPU Usage

ID	GPU	MEM
0	0%	0%
1	0%	0%
2	0%	0%
3	0%	0%

GPU Usage after allocating a bunch of Tensors

ID	GPU	MEM
0	0%	40%
1	0%	0%
2	0%	0%
3	0%	0%

GPU Usage after deleting the Tensors

ID	GPU	MEM
0	0%	40%
1	0%	0%
2	0%	0%
3	0%	0%

GPU Usage after emptying the cache

ID	GPU	MEM
0	0%	5%
1	0%	0%
2	0%	0%
3	0%	0%

https://blog.paperspace.com/pytorch-memory-multi-gpu-debugging/

training loop에 tensor로 축적 되는 변수는 확인할 것

- tensor로 처리된 변수는 GPU 상에 메모리 사용
- 해당 변수 loop 안에 연산에 있을 때 GPU에

  computational graph를 생성(메모리 잠식)

```
total_loss = 0
for i in range(10000):
    optimizer.zero_grad()
    output = model(input)
    loss = criterion(output)
    loss.backward()
    optimizer.step()
    total_loss += loss
```

training loop에 tensor로 축적 되는 변수는 확인할 것

- 1-d tensor의 경우 python 기본 객체로 변환하여 처리할 것

```
total_loss = 0

for x in range(10):
    # assume loss is computed
    iter_loss = torch.randn(3,4).mean()
    iter_loss.requires_grad = True
    total_loss += iter_loss
```

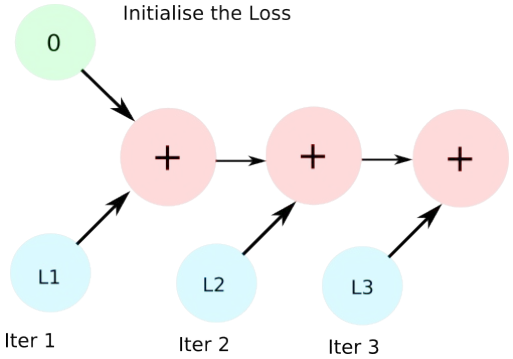

https://blog.paperspace.com/pytorch-memory-multi-gpu-debugging/

del 명령어를 적절히 사용하기

- 필요가 없어진 변수는 적절한 삭제가 필요함
- python의 메모리 배치 특성상 loop 이 끝나도 메모리를 차지함

```
for x in range(10):
    i = x

print(i)      # 9 is printed
```

```
for i in range(5):
        intermediate = f(input[i])
        result += g(intermediate)
output = h(result)
return output
```

가능 batch 사이즈 실험해보기

- 학습시 OOM 이 발생했다면 batch 사이즈를 1로 해서 실험해보기

```
oom = False

try:
    run_model(batch_size)
except RuntimeError: # Out of memory
    oom = True

if oom:
    for _ in range(batch_size):
        run_model(1)
```

torch.no_grad() 사용하기

- Inference 시점에서는 torch.no_grad() 구문을 사용
- backward pass 으로 인해 쌓이는 메모리에서 자유로움

```
with torch.no_grad():
        for data, target in test_loader:
            output = network(data)
            test_loss += F.nll_loss(output, target, size_average=False).item()
            pred = output.data.max(1, keepdim=True)[1]
            correct += pred.eq(target.data.view_as(pred)).sum()
```

예상치 못한 에러 메세지

- OOM 말고도 유사한 에러들이 발생
- CUDNN_STATUS_NOT_INIT 이나 device-side-assert 등
- 해당 에러도 cuda와 관련하여 OOM의 일종으로 생각될 수 있으며, 적절한 코드 처리의 필요함

https://brstar96.github.io/shoveling/device_error_summary/

그외…

- colab에서 너무 큰 사이즈는 실행하지 말 것
  (linear, CNN, LSTM)

- CNN의 대부분의 에러는 크기가 안 맞아서 생기는 경우
  (torchsummary 등으로 사이즈를 맞출 것)

- tensor의 float precision을 16bit로 줄일 수도 있음

End of Document
Thank You.